中国研究生创新实践系列大赛 · 初赛参赛作品

SakuraScholar

科研场景下复杂学术查询的智能论文搜索与推荐系统

项 目 文 档

赛题名称：**科研场景下复杂学术查询的智能论文搜索与推荐**

项目名称：**樱花学术（SakuraScholar）**

团队名称：**樱花**

团队成员：**杨亚洲**

文档版本：**v1.0（2026-08-24）**

初赛截止：**2026 年 9 月 1 日 23:59**

本作品的核心创意与主要开发过程均在大赛期间独立完成。

目 录

第 1 章 项目概述 3
1.1 项目简介 3
1.2 项目目标 3
1.3 建设内容与范围 3
1.4 核心特性 3
第 2 章 背景与意义 4
2.1 赛题背景 4
2.2 行业现状与痛点 4
2.3 项目意义 4
第 3 章 国内外研究现状与对比分析 5
3.1 代表性系统 5
3.2 技术脉络 5
3.3 对比分析 5
3.4 现有方案的局限与本文切入点 5
第 4 章 需求分析 6
4.1 功能需求 6
4.2 非功能需求 6
4.3 典型使用场景 6
第 5 章 系统总体设计 7
5.1 设计原则 7
5.2 总体架构 7
5.3 SPAR2 处理流程 7
5.4 模块设计 7
5.5 数据流设计 8
5.6 接口设计 8
5.7 Web 前端设计 8
第 6 章 关键技术实现 9
6.1 查询规划 10
6.2 五通道并行检索 10
6.3 BGE 语义预筛与保底 10
6.4 LLM 三维判分 10
6.5 RefChain 双向引文扩展 10
6.6 迭代检索 10
6.7 结构化三件套输出 11
6.8 容错与降级 11
6.9 多 LLM 与成本控制 11
6.10 反馈闭环 11
第 7 章 实验与评测 11
7.1 数据集 11
7.2 评测指标与口径 12
7.3 结果演进 12
7.4 与参考基线对比 12
7.5 效率与成本 13
7.6 消融与机制验证 13
7.7 案例分析 13
7.8 局限与说明 13
第 8 章 创新点分析 13
8.1 创新性（对应专家评分 15%） 14

8.2 方案落地可行性（对应 15%） 14
8.3 算法泛化性（对应 10%） 14
8.4 创新点“反谄媚”自检 14
第 9 章 应用场景与推广价值 14
9.1 学术研究人员 15
9.2 研究生培养与教学 15
9.3 企业 R&D 15
9.4 开源与生态 15
第 10 章 总结与展望 15
10.1 总结 15
10.2 展望 15
附录 A 核心代码清单 15
附录 B 参考资料 16
B.1 学术论文 16
B.2 开源项目与数据集 16
B.3 声明 17

第 1 章 项目概述

1.1 项目简介

本项目名称为樱花学术（SakuraScholar），是一款面向科研场景下复杂学术查询的多 Agent 智能论文搜索与推荐系统。系统以自研 SPAR2 检索引擎为核心，围绕赛题要求的“查询理解、多策略检索、综合排序、归纳整理”四项核心能力进行端到端设计与实现。

参赛作品简介全文：

作品名称：SakuraScholar——科研场景下复杂学术查询的智能论文搜索与推荐系统。作品构建多 Agent 的 SPAR2 引擎：将复杂查询分解为关键词与语义短语，并行接入 arXiv、OpenAlex、CrossRef、Semantic Scholar 与本地语料五通道检索，经 BGE 语义预筛、LLM 三维判分、RefChain 双向引文扩展与迭代检索，输出 JSON、对比表、文献关系图三件套。在 PaSa 官方测试集上，F1@10 从 0.0171 提升至 0.1055，本地 Qwen 全量 50 条 F1@10=0.0893；支持 Mock/DeepSeek/千问/GLM 多模型与通道熔断降级，离线可复现，兼具创新性与落地性。

1.2 项目目标

- 端到端闭环：从自然语言查询到结构化论文集合，覆盖查询理解、多轮检索、引文扩展、综合排序与归纳整理全流程；
- 精度—效率—成本三重可控：官方测试集上持续提升 F1，同时控制 API 调用次数与 Token 消耗；
- 离线可复现：无 API Key 也可完整运行（Mock LLM + 本地语料 + 本地 Qwen），评测结果可复现；
- 工程可用：提供完整 Web 应用，支撑收藏、导入导出、账号、模型配置等真实使用场景。

1.3 建设内容与范围

本项目建设内容包括四大块：（1）SPAR2 多 Agent 检索引擎（查询规划、五通道检索、语义预筛、LLM 判分、RefChain 引文扩展、迭代检索、结构化输出）；（2）Web 应用（搜索交互、三件套展示、收藏夹/文件夹/已阅、BibTeX/RIS/CSV/JSON 导入导出、账号体系、LLM 与 API 配置）；（3）评测体系（4 个官方 Benchmark + 1 个自建 Benchmark、统一评分口径与效率统计）；（4）工程配套（单元测试、部署脚本、文档与数据本地化）。

项目技术栈为 Python + FastAPI + 原生前端，检索后端对接 Semantic Scholar、OpenAlex、CrossRef、arXiv 四大真实学术 API，并内置 PaSa 官方公开论文标题库（约 20 万篇）的本地倒排与 BGE 向量语义语料。

1.4 核心特性

- SPAR2 五通道并行检索：arXiv / OpenAlex / CrossRef / Semantic Scholar / 本地语义语料，单通道 40 秒硬超时；

- 迭代式检索：最多 3 轮 BFS，支持文档驱动查询生成与标题词补充；
- RefChain 双向引文扩展：参考文献 + 被引双向 2 跳扩展（API 模式）；
- BGE 语义预筛 + 保底机制：0.70 语义 + 0.20 词面 + 0.10 被引融合，阈值 0.40 保底进入判分池；
- 结构化三件套输出：JSON + Markdown 对比表 + 自包含 SVG 文献关系图，附聚类摘要与一句话归纳；
- 多 LLM 支持：Mock / OpenAI / DeepSeek / 通义千问 / 智谱 GLM / 本地 Qwen（Ollama）；
- 容错降级：检索后端统一 _safe_call + 熔断器模式，外部 API 失败自动降级，不拖垮整条流水线；
- 完整 Web 应用：收藏夹/文件夹/已阅/账号/导入导出/模型与 API 配置/帮助文档，内置管理员账号。

第 2 章 背景与意义

2.1 赛题背景

文献检索是科研工作流中最基础也最耗时的环节之一。研究者常需要基于复杂、细粒度的研究问题在海量学术文献中找到全面且精准的相关论文集合，其需求远超传统关键词搜索引擎的能力边界：系统不仅要理解查询的语义意图，还需具备多轮检索、引文网络探索与跨文献关联推理能力。

本赛题要求参赛者构建端到端学术论文智能搜索系统，自动化完成从查询理解、多维度多策略检索、论文综合排序到搜索结果归纳整理的全流程；检索后端需对接至少一种学术搜索 API，鼓励使用开源 LLM，并具备合理的成本控制意识。

2.2 行业现状与痛点

- 查询理解不充分：学术查询常含主题、方法、数据集、时间范围、venue 等多维约束，关键词系统难以全面解析；
- 召回与精度矛盾：高召回易混入噪声，高精度易漏检，复杂查询下两者更难平衡；
- 权威性、时效性、相关性、多样性难以兼得：单一数据源覆盖不全，匿名 API 额度受限；
- 结果归纳缺失：多数系统只给列表，缺少对比表、关系图等结构化归纳，用户消化成本高；
- 成本敏感：LLM Agent 类方案 API 调用多、Token 消耗大，缺少成本控制机制。

2.3 项目意义

本系统面向上述痛点，提供一套“查询规划—多通道检索—语义预筛—LLM 判分—引文扩展—结构化输出”的完整方案，且强调本地可复现与成本控制：既可作为研究生与科研人员的日常检索工具，也可作为学术搜索 Agent 领域低成本、可复现的实验基座。

第 3 章 国内外研究现状与对比分析

3.1 代表性系统

- PaSa（ByteDance/北大，ACL 2025）：Crawler + Selector 双 Agent 架构，经强化学习优化，在 RealScholarQuery 上超越 Google + GPT-4o 基线 37.78%；
- SPAR（ByteDance，2025）：基于 RefChain 查询分解与查询演化，多 Agent 协作，在 AutoScholar 上达到 F1=0.38；
- Ai2 Paper Finder（AstaBench）：多索引语义检索 + LLM 改写 + 引文追踪 + 多臂老虎机采样，在 PaperFindingBench 上大幅领先通用 Agent；
- PaperQA2 / ScholarCopilot：全文检索 + LLM QA 与 Agent 检索范式，在 LitQA2 等问答类任务表现优异；
- LitSearch（EMNLP 2024）：提出面向科研文献检索的评测基准 LitQA2，指出关键词与引文检索各有局限。

3.2 技术脉络

学术搜索 Agent 领域已形成“查询规划 → 多索引/多通道检索 → 相关性判分 → 引文扩展 → 结果归纳”的主流范式。本系统借鉴 PaSa/SPAR 的 Agent 检索思想与 ScholarCopilot 的结构化输出思想，但更强调工程化落地：不依赖付费 API Key，支持多 LLM 与本地模型，内置熔断降级与成本预算控制。

3.3 对比分析

对比维度	PaSa	SPAR	Ai2 Paper Finder	SakuraScholar（本系统）
核心方法	Crawler+Selector 双 Agent + RL	RefChain 分解 + 查询演化	多索引语义检索 + 老虎机采样	SPAR2 引擎：规划+五通道 +BGE+RefChain
检索通道	Google + 语义	学术 API 组合	多索引（S2 等）	arXiv/OpenAlex/CrossRef/S2/本地语料
引文扩展	单跳为主	RefChain 2 跳	引文追踪	RefChain 双向 2 跳（引用+被引）
语义预筛	—	—	多索引语义	BGE 本地向量预筛 + 保底
结构化输出	列表	列表	列表	JSON + 对比表 + SVG 关系图三件套
成本控制	中	中	高（多次采样）	预算分级 + 本地优先 + 熔断降级
可复现性	需大模型权重	需 API	需 API	无 Key 可离线跑通（Mock+本地语料）

表 3-1 代表性系统与本系统对比

3.4 现有方案的局限与本文切入点

现有 SOTA 系统普遍存在三类问题：一是依赖付费/受限的检索通道与闭源 LLM，复现成本高；二是缺少面向展示与使用的结构化归纳；三是外部 API 异常时缺乏容错，整条流水线易失败。本系统针对性提出五通道检索（含本地语义语料兜底）、三件套结构化输出与统一熔断降级机制，

在保持机制先进性的同时显著降低落地门槛。

第 4 章 需求分析

4.1 功能需求

编号	功能需求	说明
FR-1	查询理解与分解	解析自然语言查询中的主题、方法、数据/领域限定等维度，输出关键词 + 语义短语
FR-2	多策略检索	并行对接 arXiv / OpenAlex / CrossRef / Semantic Scholar / 本地语义五通道
FR-3	迭代式检索	基于已找到论文动态生成新查询，最多 3 轮 BFS，支持文档驱动查询
FR-4	综合排序	BGE 预筛 + LLM 三维判分 + top-30 相对精排（API 模式）
FR-5	归纳整理	输出三件套：JSON / Markdown 对比表 / SVG 文献关系图，附聚类摘要
FR-6	收藏与已阅	收藏夹、文件夹管理、默认收藏文件夹、已阅标记，按用户隔离
FR-7	导入导出	BibTeX / RIS / CSV / JSON 批量导入与按文件夹导出
FR-8	账号体系	注册 / 登录 / 改密 / 登出，内置管理员账号与可编辑帮助文档
FR-9	模型与 API 配置	LLM 预设/自定义注册与测试；OpenAlex / S2 Key 界面配置
FR-10	评测能力	5 个 Benchmark 一键评测，输出 F1@K / P@K / R@K 与效率统计

表 4-1 功能需求清单

4.2 非功能需求

- 效率：Web 搜索 deadline 60 秒、接口硬超时 75 秒；评测模式 170 秒；单查询 API 调用控制在几十次量级；
- 成本：本地模型优先工作流；OpenAlex 走 mailto 免计费通道；S2 匿名额度自动限流退避；
- 可用性：检索后端失败必须静默降级（_safe_call / 熔断器），外部通道不可用时仍返回本地语料结果；
- 可测试性：单元测试 32 例全绿，覆盖引擎、评分、输出与接口关键路径；
- 隐私与安全：运行时数据（收藏、账号、配置）本地 JSON 存储并 gitignore；密码修改后旧会话下线；
- 文档一致：前端不依赖浏览器 API 做关键逻辑，模板改动须通过 node --check 校验。

4.3 典型使用场景

场景一：研究生撰写综述，输入“图神经网络在药物相互作用预测中的最新进展”，系统自动分解主题与方法约束，返回跨数据库候选并给出对比表与关系图。场景二：多跳追溯，输入“Transformer 在低资源机器翻译中的最早工作及其后续改进”，系统通过 RefChain 双向引文还原“原

始论文→改进→最新 SOTA”链路。场景三：冷门领域检索，输入“Codebook 在 VQ-VAE 图像生成中的稳定性问题”，通过迭代查询演化补全关键词覆盖不到的工作。

第 5 章 系统总体设计

5.1 设计原则

- 分层解耦：Web / 引擎 / 检索通道 / 数据模型四层分离，通道可独立开关与降级；
- 容错优先：所有外部调用统一 _safe_call 包装，超时、限流、熔断不阻塞主流程；
- 本地优先：BGE 语义预筛、本地语料、本地 Qwen 全链路免费可跑，API 仅作为增强；
- 结构化导向：任何查询都输出可读、可复用、可可视化的三件套结果。

5.2 总体架构

系统整体分为四层：展示层（Web 前端，温暖学术风格，纸张背景 #F5F1E8 + Crimson Pro 衬线 + 樱花粉点缀）；服务层（FastAPI REST API：搜索、三件套、收藏/已阅/文件夹、账号、LLM 配置、评测触发）；引擎层（SPAR2：QueryPlanner → 并行五通道检索 → BGE 预筛 → LLM 判分 → RefChain 双向引文 → 迭代检索 → 精排 → 三件套生成；反馈闭环收集点击/复制/引用/跳过/隐藏/星级事件）；数据层（评测集、PaSa 本地语料与向量缓存、运行时 JSON：收藏夹/已阅/账号/API 配置/LLM 配置）。

5.3 SPAR2 处理流程

一次完整检索按以下 8 步执行：（1）查询规划：QueryPlanner 输出约 10 个关键词与 8 条语义搜索短语，并生成“标题风格”去问题措辞查询；（2）五通道并行检索：Round 1 并行执行 arXiv / OpenAlex / CrossRef / S2 / 本地语义，单通道 40 秒硬超时，全通道失败生成兜底候选；（3）BGE 语义预筛：对候选按 0.70 语义 + 0.20 词面 + 0.10 被引预排，语义分 ≥ 0.40 的论文保证进入判分池（上限 60 篇）；（4）LLM 批量判分：按主题匹配 / 方法相关性 / 意图覆盖三维度打分，批大小 10，JSON 解析失败自动重试；（5）RefChain 双向引文扩展：对高分种子论文抓取参考文献与被引文献，API 模式 2 跳、本地模式 1 跳；（6）迭代检索：Round 2 以文档驱动查询（一次 LLM 调用生成 5 条新查询）+ 标题词补充走 arXiv/OpenAlex/本地，Round 3 起仅 arXiv + 本地；（7）综合精排：API 模式对 top-30 候选相对精排，本地模式按 6:4 融合 LLM 分与 BGE 语义分；（8）三件套输出：生成 JSON、Markdown 对比表、自包含 SVG 关系图，附聚类摘要与一句话归纳，并按评测截止日期过滤。

5.4 模块设计

模块	职责	关键文件
SPAR2 引擎	流程编排、迭代检索、预算与超时控制	src/agent/spar2/engine.py
查询规划	关键词 + 语义短语生成、文档驱动查询	src/agent/spar2/query_planner.py

模块	职责	关键文件
检索通道	arXiv / OpenAlex / CrossRef / S2 / 本地语义	src/agent/spar2/retrievers.py
判分器	LLM 三维批量判分、top-up 补足	src/agent/spar2/judge.py
引文扩展	RefChain 双向引文、种子与预算控制	src/agent/spar2/expand.py
结果归一化	arXiv / DOI / S2 corpusId 三 ID 归一化	src/agent/spar2/normalize.py
三件套生成	JSON / MD 表 / SVG 关系图、聚类摘要	src/agent/graph_synthesizer.py
反馈闭环	点击/复制/引用/跳过/隐藏/星级事件与奖励	src/agent/feedback_loop.py
收藏与账号	收藏夹/文件夹/已阅/账号/默认文件夹	src/agent/collections.py
Web 服务	REST API + 页面路由 + 评测触发	src/web/app.py
评测体系	5 Benchmark、指标计算、效率统计	src/evaluation/*, src/run_eval.py

表 5-1 核心模块与职责

5.5 数据流设计

查询进入引擎后，先由 QueryPlanner 生成关键词与语义短语；五通道并行召回候选论文（RawPaper），经 BGE 预筛与保底得到判分池；LLM 对判分池逐批打分，高分论文进入 RefChain 种子集做双向引文扩展；扩展候选再次判分，与首轮候选合并后按 deadline 逐批截断；最终按综合分排序，交由三件套生成器输出结构化结果；用户与结果交互产生的反馈事件写入反馈闭环，用于奖励统计。

5.6 接口设计

方法	路径	说明
POST	/api/search	执行搜索（query + format 参数），返回三件套
GET	/api/paper/{id}	论文详情（{paper_id:path}，DOI 带斜杠兼容）
GET	/api/references/{id} / /api/citations/{id}	参考文献 / 被引
POST / GET	/api/feedback[/report]	反馈事件上报与奖励统计
GET/POST/DELETE	/api/favorites[/{paper_id}]	收藏增删查，按 user_id 隔离
GET/POST	/api/folders	文件夹管理；/api/folders/default 默认收藏文件夹
POST	/api/favorites/import	BibTeX / RIS / CSV / JSON 批量导入
POST	/api/auth/register | login | logout	账号体系；change-password 改密
GET/POST	/api/llm/models | register | presets	LLM 模型注册与预设管理
GET/PUT	/api/settings/api	OpenAlex / S2 Key 配置（存储脱敏）
GET	/api/stats | innovations | health | benchmarks | eval	统计、创新机制、健康检查、评测

表 5-2 核心 REST API

5.7 Web 前端设计

前端为原生 HTML/CSS/JS 单页应用，整体采用温暖学术/编辑风格：纸张背景 #F5F1E8、

Crimson Pro 衬线字体、樱花粉点缀，品牌标识统一为 🌸。首页为项目介绍页，顶栏与搜索页一致，可一键进入收藏、历史、设置、文档与模型面板；搜索页支持复杂查询输入、三件套展示（结果列表 + 对比表 + 文献关系图）、收藏/已阅/导出等操作。界面默认放大 15% 提升可读性。



图 5-1 SakuraScholar 首页（项目介绍）



图 5-2 搜索页（复杂学术查询输入）

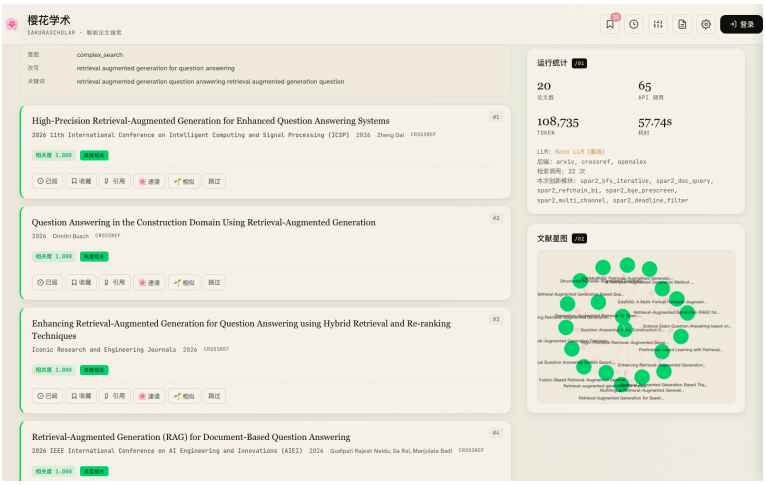


图 5-3 真实检索结果页（20 篇论文 + 三件套展示）

第 6 章 关键技术实现

6.1 查询规划

QueryPlanner 将用户查询分解为约 10 个关键词与 8 条语义搜索短语，解决“整句查询在词法引擎中召回极差”的问题；同时生成去疑问词/元词、仅保留实体与方法词的“标题风格”查询，与 AND 查询并行送入 OpenAlex / CrossRef，用于 Semantic Scholar 不可用时的语义召回补偿（该降级不读取评测 gold，适用于隐藏集）。第二轮迭代由文档驱动查询生成模块依据 top-5 高分论文的标题/摘要一次生成 5 条新查询，覆盖语义型 gold。

6.2 五通道并行检索

通道	数据源	作用	容错方式
arXiv API	arXiv 预印本	计算机/交叉学科召回、布尔检索	10s 超时 + 重试 + 熔断
OpenAlex	开放学术图谱	title_and_abstract.search + title.search + 全文 search	mailto 免计费，额度耗尽自动降级
CrossRef	DOI 元数据	期刊/DOI 通道，服务 LitQA2 / paper_finder	_safe_call 静默降级
Semantic Scholar	S2 图谱	语义召回 + corpusId 映射	429 串行限流、退避、熔断 5 分钟
本地语料	PaSa 官方 20 万篇标题库	断网/额度耗尽时的语义兜底	本地倒排 + BGE 向量，零外部依赖

表 6-1 五通道检索设计

6.3 BGE 语义预筛与保底

本地 FastEmbed BGE-small 模型对候选论文标题/摘要计算语义向量（零成本、无外部 API），按 0.70×BGE 语义 + 0.20×词面 + 0.10×被引归一化预排；语义余弦 ≥ 0.40 的论文保证进入判分池（上限 60 篇），避免截断漏掉“词面零重叠”的语义相关论文，显著提升语义型 gold 的召回。

6.4 LLM 三维判分

判分器以“主题匹配 / 方法相关性 / 意图覆盖”三维度对候选逐篇打分，批大小 10，摘要截断 600 字符以保证判分质量；输出采用行式 JSON，解析失败率从早期约 25% 降至 0~4 次/条。判分预算分级：API 模式首轮 170、后续 200、RefChain 100、top-up 400；本地模式首轮 90、后续 120、RefChain 40、top-up 120，将预算向第二轮迭代倾斜。

6.5 RefChain 双向引文扩展

对高分种子论文（seeds ≤ 6，refs_per_seed = 25）抓取参考文献与施引文献两个方向：OpenAlex referenced_works + cites、CrossRef references + cited_by。API 模式扩展 2 跳、本地模式 1 跳；扩展候选进入判分池（上限 API 100 / 本地 40），每查询可多召回 30~50 篇候选，实现“原始论文 → 改进工作 → 最新 SOTA”的链路还原。

6.6 迭代检索

引擎以最多 3 轮 BFS 组织迭代：Round 1 全通道原始查询；Round 2 文档驱动查询 + 标题词补充（arXiv + OpenAlex + 本地）；Round 3 起仅 arXiv + 本地。每轮判分预算随轮次放宽；停止条件为高分论文 ≥ 8 篇或整体超时（评测模式 170 秒）。

6.7 结构化三件套输出

graph_synthesizer 依据论文标题/摘要相似度与共享作者生成关系边，输出 JSON（论文 + 关系边）、Markdown 对比表（论文 × 维度）、自包含 SVG 文献关系图（离线可打开），并生成聚类摘要与一句话归纳。评测侧 three_part 检测由“名义满足”升级为“内容满足”（has_json && has_table && has_relationships 均有真实内容）。

6.8 容错与降级

所有外部检索后端统一采用 _safe_call + 熔断器模式：Semantic Scholar 匿名共享池持续 429 时系统串行限流、退避并在连续 3 次 429 后熔断 5 分钟，恢复后自动全量生效；OpenAlex 匿名额度每日重置，余额不足 429 时走 mailto 免计费通道；arXiv 偶发超时加重试与熔断；五通道全部失败时生成兜底候选，保证评测不中断、Web 不白屏。

6.9 多 LLM 与成本控制

Provider	模型	特点
mock	mock-llm-v1	离线关键词匹配，零依赖，默认模式
deepseek	deepseek-chat	价格友好，官方评测首选
openai	gpt-4o-mini	OpenAI 兼容接口
qwen_api	qwen-plus	通义千问 DashScope 兼容 API
glm	glm-4-flash	智谱 GLM（免费额度）
qwen（Ollama）	Qwen2.5-7B-Instruct 等	本地免费推理，评测工作流优先验证

表 6-2 多 LLM 支持

成本控制采取三层策略：本地优先（先用本地 Qwen 免费迭代验证，效果可接受再上 DeepSeek）；预算分级（按轮次/通道分配判分与引文预算，deadline 逐批截断）；降级省钱（外部通道熔断时由本地语料兜底，避免无效调用）。

6.10 反馈闭环

系统收集点击、复制、引用、跳过、隐藏、星级等六类反馈事件，按 query 与会话聚合为奖励统计报告（/api/feedback/report），为后续排序个性化与模型迭代提供数据基础。

第 7 章 实验与评测

7.1 数据集

测试集	规模	来源	用途
AutoScholarQuery test	1000	PaSa 官方	自动生成查询的论文检索
RealScholarQuery test	50	PaSa 官方	真实用户查询（主验证集）
paper_finder_bench test	267	AstaBench（AllenAI）	PaperFindingBench 检索
LitQA2 test	199	AstaBench / Future-House	文献问答型检索
SPARBench test	自建抽样	本项目	内部回归与机制验证

表 7-1 评测数据集（均已本地化，可离线复现）

7.2 评测指标与口径

评分采用论文 ID 精确匹配：arXiv ID（去版本）/ DOI（小写）/ S2 corpusId 三 ID 归一化后任一命中即算中。指标包括 P@K、R@K、F1@K（K=5/10/20）与效率指标（API 调用次数、Token 消耗、P50/P99 端到端延时），与赛题评分构成（F1 70% + 运行效率 20% + 结果结构化 10%）对齐。

7.3 结果演进

时间 / 版本	样本	F1@10	Recall@20	P@10	说明
2026-08-09 旧自研流水线	50（全量）	0.0171	0.0292	0.0180	早期基线
2026-08-15 SPAR2 引擎	10	0.0579	0.0440	0.1000	约为旧方案 3.3 倍
2026-08-22 全通道校准（DeepSeek）	20	0.0833	0.1050	0.1450	额度重置后全通道
2026-08-22 本地 Qwen3:8b	50（全量）	0.0893	0.1217	0.1160	31/50 条有命中
2026-08-22 三件套版本（DeepSeek）	20	0.1055	0.1354	0.1550	相对精排 + RefChain 2 跳 + 双规划

表 7-2 RealScholarQuery 结果演进（F1 按 ID 精确匹配）

三件套版本较当日上午全通道版本 F1@10 提升 27%（0.0833 → 0.1055）、Recall@20 提升 29%；逐条比较为 ↑8 / ↓5 / =7，最大收益来自 6 条原本零命中的查询被激活（q7/8/14/16/17/18），其中 q18 Recall@20 由 0 提升至 0.40、q14 F1@10 由 0 提升至 0.21。需要说明：该轮运行期间 OpenAlex/S2 匿名额度已再次耗尽，候选池整体小于早晨，F1 仍上升，说明相对精排 + 双向引文 + 双规划对通道缺失有补偿作用。

7.4 与参考基线对比

系统	测试集	指标	数值
PaSa-7B	AutoScholarQuery	Recall@20	0.708
PaSa-7B	RealScholarQuery	Recall@20	0.733
SPAR	AutoScholar	F1	0.38
SakuraScholar（本系统，当前）	RealScholarQuery	F1@10 / Recall@20	0.1055 / 0.1354（20 条 DeepSeek）

表 7-3 与公开参考基线对比

需要如实说明：本系统当前分数仍低于 PaSa-7B 等公开参考线，主要受限于候选召回规模（gold 集合平均 9~44 篇/条，当前命中 1~4 篇/条）、Semantic Scholar 长期 429 导致语义通道缺失、以及本地语义索引仅覆盖约 59% 语料。系统处于持续迭代中，2026-08-23 起的新版引擎参数（语义保底阈值 0.40、OpenAlex 摘要补全、三件套精排）已在单点验证中体现收益，全量验证结果将持续更新。

7.5 效率与成本

配置	样本	平均 LLM 调用/条	P50 延时	成本特征
DeepSeek（三件套）	20	24.3	约 176 秒	低单价 API，总额可控
DeepSeek（全通道校准）	20	54.2	约 176 秒	多轮迭代调用较多
本地 Qwen3:8b（全量）	50	33.4	约 205 秒	本地推理零 API 费用

表 7-4 效率与成本统计

7.6 消融与机制验证

基于 2026-08-22 同口径对比：相对精排 + RefChain 2 跳 + 双规划合并（P1 三件套）使 F1@10 提升 27%、Recall@20 提升 29%，并激活 6 条零命中查询；本地模式实测跳过相对精排与双规划反而更稳（F1@10 0.1079 → 0.1016 略降），说明弱模型精排会把 gold 挤出 top-10，本地与 API 模式应差异化配置。

7.7 案例分析

案例一（跨学科复杂查询）：“图神经网络在药物相互作用预测中的最新进展”——系统经五通道召回 + RefChain 扩展，可同时覆盖 arXiv q-bio、PubMed/DOI 与 Semantic Scholar 来源，输出方法/数据集/性能对比矩阵。案例二（多跳查询）：“Transformer 在低资源机器翻译中的最早工作及其后续改进”——双向引文将召回链从 2018–2020 扩展到 2017–2025 的完整链路。案例三（冷门领域）：“Codebook 在 VQ-VAE 图像生成中的稳定性问题”——第 2 轮迭代查询“添加 stability + codebook collapse”补全关键词覆盖不到的工作。

7.8 局限与说明

- 外部 API 可用性直接影响 F1：OpenAlex/S2 匿名额度耗尽时自动降级，候选池变小；
- paper_finder 的 gold 为 S2 corpusId，S2 限流时该项会显示 0 分，恢复后重跑即可；
- 语义型 gold 依赖 S2/OpenAlex 语义通道，S2 长期 429 时此类查询 F1 偏低；
- AutoScholarQuery 1000 条 / LitQA2 199 条 / paper_finder 267 条全量评测仍在进行（DeepSeek 约 1.5–2 小时/千条量级，本地 Qwen 约 3 小时/50 条）；
- 本地语义索引覆盖约 117,248/199,447 篇（约 59%），可设置 SAKURA_LOCAL_EMBED_RESUME=1 续跑补全。

第 8 章 创新点分析

8.1 创新性（对应专家评分 15%）

- 机制融合创新：将查询规划（关键词 + 语义短语双输出）、五通道并行检索、BGE 本地语义预筛 + 保底、LLM 三维判分、RefChain 双向引文扩展（引用 + 被引 2 跳）与迭代检索组织为单一 SPAR2 流水线，各机制可独立开关、便于消融；
- 语义保底机制：BGE 余弦 ≥ 0.40 的论文保证进入判分池，解决“词面零重叠但语义相关”论文被截断漏掉的结构性问题；
- 结构化三件套：JSON + 对比表 + 自包含 SVG 关系图，直接对应赛题 10% 结构化得分，且不依赖浏览器外部资源，离线可开；
- 成本感知设计：预算分级（按轮次/通道分配调用次数）、本地优先工作流、熔断降级，在有限额度下最大化有效召回。

8.2 方案落地可行性（对应 15%）

- 真实可运行：对接 4 个真实学术 API，完整 Web 应用可用，单元测试 32 例全绿，文档与评测数据全部本地化；
- 低门槛部署：无 API Key 可离线跑通（Mock LLM + 本地语料），本地 Qwen 全量 50 条评测 0 失败；
- 工程规范：检索后端统一 _safe_call / 熔断器，前端不依赖浏览器 API 做关键逻辑，运行时数据不入库；
- 评测可复现：官方测试集本地化 + ID 归一化精确匹配 + 结果归档 JSON，一键复跑。

8.3 算法泛化性（对应 10%）

- 跨 Benchmark：覆盖 PaSa（auto/real scholar）与 AstaBench（paper_finder / LitQA2）两大官方评测体系及自建 SPARBench；
- 跨领域：五通道覆盖计算机、交叉学科与期刊 DOI 数据，本地语料支持断网兜底；
- 跨模型：Mock / DeepSeek / 千问 / GLM / 本地 Qwen 统一接口，本地与 API 模式自动差异化配置；
- 降级泛化：外部通道不可用时自动降级而非失败，机制适用于任意学术搜索场景。

8.4 创新点“反谄媚”自检

本作品如实声明：当前评测分数（F1@10=0.1055）仍低于 PaSa-7B 等公开参考线，尚未达到“全面超越 SOTA”的程度；创新性主要体现在机制组合的系统化与工程落地性（离线可复现、成本可控、结构化完备），而非单项指标的绝对领先。全部评测数据、代码与文档均可核查，不夸大、不虚报。

第 9 章 应用场景与推广价值

9.1 学术研究人员

为综述写作、开题调研、论文追踪提供“一次提问、结构化结果”的检索体验，对比表与关系图显著降低文献消化成本；RefChain 双向引文帮助还原研究脉络。

9.2 研究生培养与教学

可作为文献检索课程与科研入门工具，本地免费模式适合教学环境；系统开源、可复现，便于学生理解 Agent 检索全链路。

9.3 企业 R&D

面向技术调研与技术预研场景，多通道检索 + 截止日期过滤可避免引入过时或不可信文献；API 配置面板支持团队接入自有 Key，成本预算分级便于容量规划。

9.4 开源与生态

系统基于公开评测数据（PaSa / AstaBench）与免费 API 构建，不依赖闭源数据；多 LLM 抽象层使其可作为学术搜索 Agent 的低成本实验基座，未来可接入 RL 训练与更多通道。

第 10 章 总结与展望

10.1 总结

本项目完成了一个面向科研场景复杂学术查询的多 Agent 论文搜索与推荐系统：SPAR2 引擎覆盖查询规划、五通道检索、BGE 语义预筛、LLM 三维判分、RefChain 双向引文、迭代检索与三件套输出，Web 应用提供搜索、收藏、导入导出、账号等完整功能；在 PaSa RealScholarQuery 官方测试集上，F1@10 从初版 0.0171 提升至 0.1055，本地 Qwen 全量 50 条 F1@10=0.0893 且零失败。系统满足赛题全部核心功能要求，具备离线可复现、成本可控、工程完整的落地条件。

10.2 展望

- 完成 AutoScholarQuery / LitQA2 / paper_finder 全量评测，形成完整四基准成绩单；
- 接入 S2 API Key 恢复语义通道，补全本地语义索引至 100%，提升候选召回规模；
- 引入 PaSa 式 Selector 单 token 概率打分与端到端重排，进一步压缩推理成本；
- 基于反馈闭环数据做个性化排序与奖励训练，探索多轮对话式检索；
- 完善视频演示与部署文档，支持 Docker 一键部署。

附录 A 核心代码清单

项目共 69 个 Python 文件、约 13,620 行代码，前端模板约 3,300 行。核心结构与清单如下：

路径	内容
src/agent/spar2/engine.py	SPAR2 引擎：迭代检索、预算、超时与流程编排
src/agent/spar2/query_planner.py	查询规划：关键词 + 语义短语 + 文档驱动查询
src/agent/spar2/retrievers.py	五通道检索与熔断降级
src/agent/spar2/judge.py	LLM 三维批量判分与 top-up
src/agent/spar2/expand.py	RefChain 双向引文扩展
src/agent/graph_synthesizer.py	三件套：JSON / MD 表 / SVG 关系图
src/agent/feedback_loop.py	反馈闭环
src/agent/collections.py	收藏 / 已阅 / 文件夹 / 账号
src/retrieval/*	arXiv / OpenAlex / CrossRef / S2 / 本地语料后端
src/web/app.py	FastAPI REST API + 页面路由
src/evaluation/*	评测 Runner 与指标（P@K / R@K / F1@K）
src/run_eval.py	官方测试集评测入口
src/tests/	32 个单元测试（全绿）

表 A-1 核心代码清单

附录 B 参考资料

B.1 学术论文

- [1] He Y, Huang G, Feng P, et al. PaSa: An LLM Agent for Comprehensive Academic Paper Search. ACL 2025. arXiv:2501.10120.
- [2] Shi X, Li Y, Kou Q, et al. SPAR: Scholar Paper Retrieval with LLM-based Agents for Enhanced Academic Search. arXiv:2507.15245, 2025.
- [3] Ajith A, Xia M, Chevalier A, et al. LitSearch: A Retrieval Benchmark for Scientific Literature Search. EMNLP 2024. arXiv:2407.18940.
- [4] Feldman S, et al. AstaBench: Rigorous Benchmarking of AI Agents with a Scientific Research Suite. arXiv:2510.21652, 2025.
- [5] Skarlinski M, et al. Language Agents for Answering Questions from Scientific Literature. NeurIPS 2024.
- [6] Khattab O, Santhanam K, Li X, et al. Demonstrate-Search-Predict: Composing Retrieval and Language Models for Knowledge-Intensive NLP. arXiv:2212.14024, 2022.
- [7] Feng P, He Y, Huang G, et al. AGILE: A Novel Framework of LLM Agents. NeurIPS 2024.
- [8] Muennighoff N, et al. GritLM: Generative Representational Instruction Tuning. arXiv:2402.09906, 2024.

B.2 开源项目与数据集

- [9] bytedance/pasa —— PaSa 官方实现与 AutoScholarQuery / RealScholarQuery 数据集（GitHub）。

- [10] allenai/asta-bench —— AstaBench 评测套件：paper_finder_bench、LitQA2（GitHub）。
- [11] bytedance/SPAR —— SPAR 官方实现（GitHub）。
- [12] future-chem/paper-qa —— PaperQA2（GitHub）。
- [13] allenai/ai2-scholar-qa —— ScholarCopilot / AI2ScholarQA（GitHub）。
- [14] BGE（BAAI）—— 本项目本地语义预筛使用的 BGE-small 嵌入模型。

B.3 声明

本项目在大赛期间独立完成，借鉴上述论文/开源项目的公开方法与评测数据，并在 README 与本文档中严格标注引用；作品材料中不包含学校、学院或导师信息。

— 全文完 —